brulion

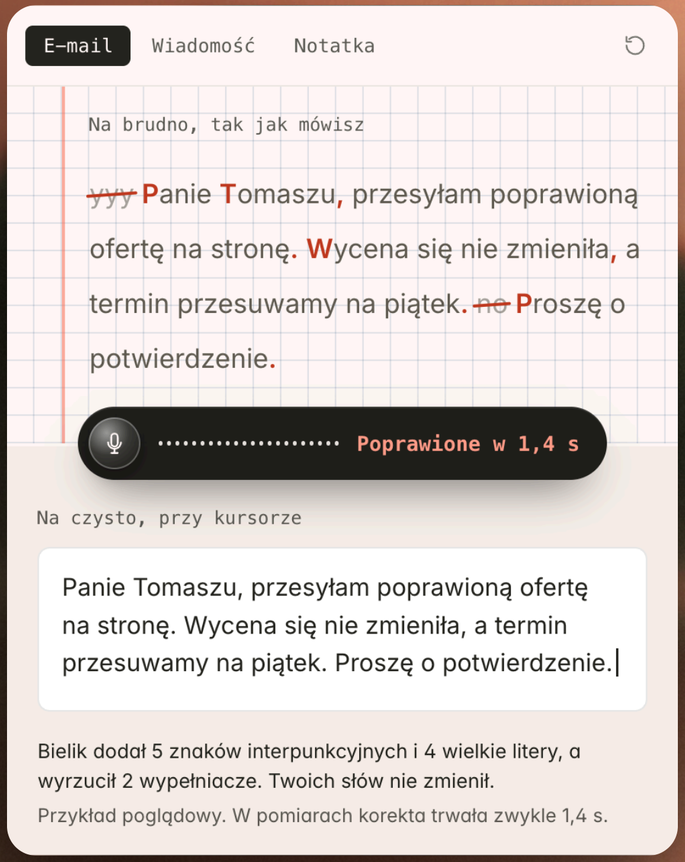
Bielik Awards 2026
Najlepsze użycie modelu SLM (<10B)

Dyktowanie i notatki ze spotkań na Macu

Mówisz na brudno. Dostajesz na czysto.

Przytrzymujesz klawisz i mówisz, a poprawiony tekst ląduje tam, gdzie piszesz. Cała warstwa językowa działa na Bieliku, lokalnie na komputerze użytkownika.

Bielik 1.5B | Bielik Minitron 7B | Whisper | llama.cpp

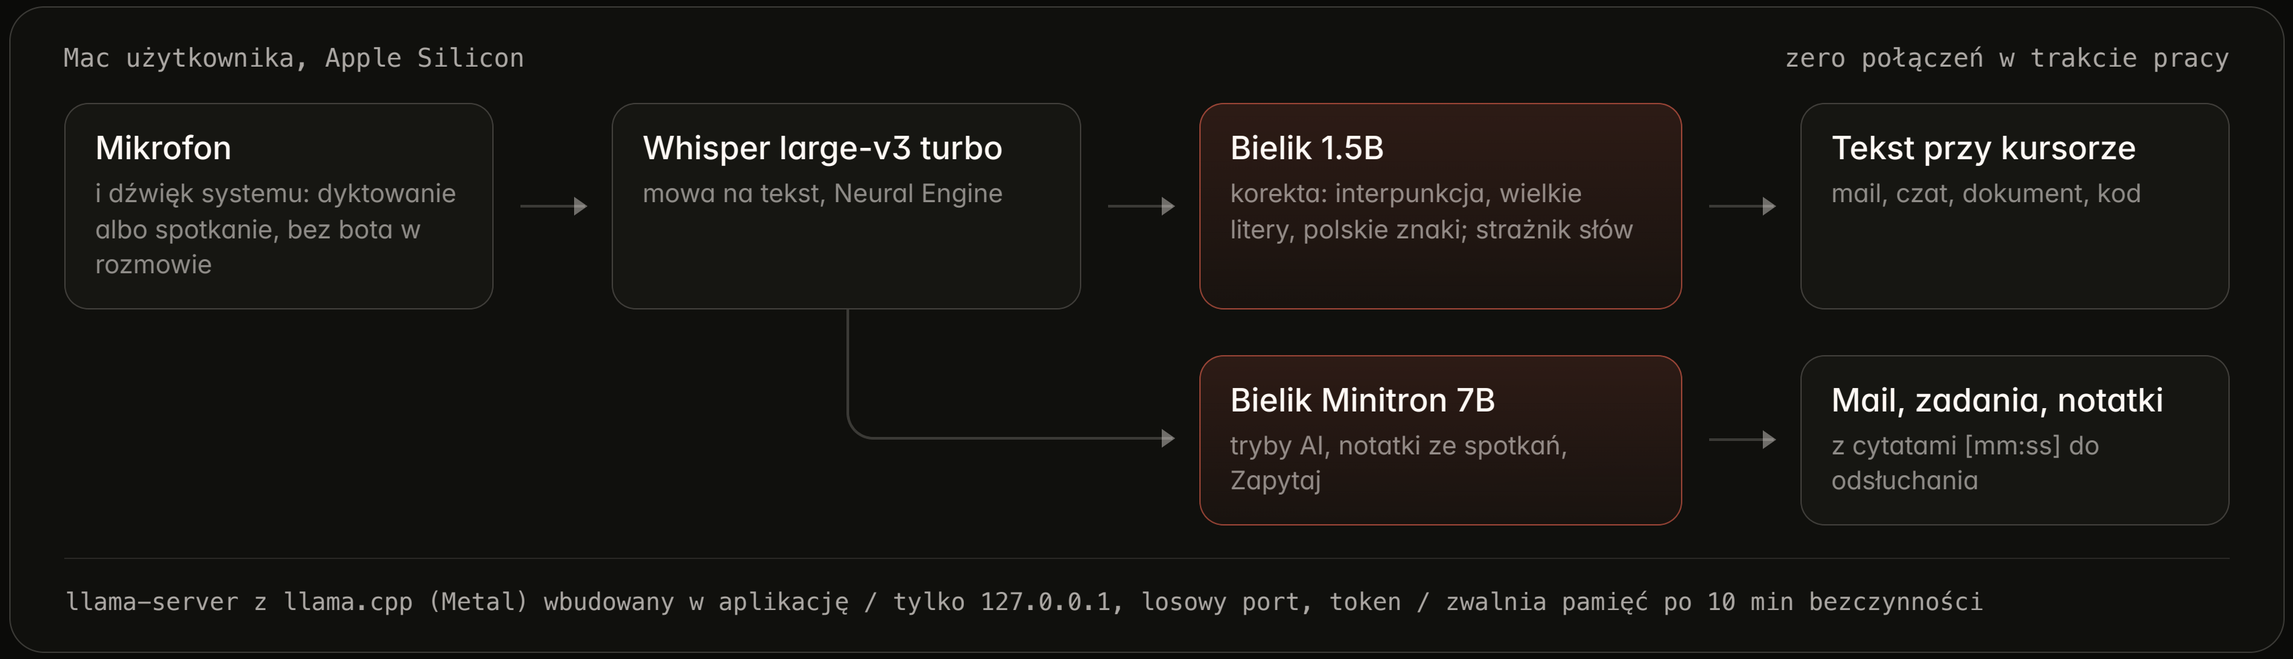


Przykład z kartki na kawalec.pl/brulion

CRAFTWEB Sp. z o.o. / Dawid Kawalec
kawalec.pl/brulion

Jak to działa

Cała AI na Macu. Sieć tylko przy pobieraniu modeli.



Sieć tylko przy pobieraniu

Modele z oficjalnych repozytoriów SpeakLeash na Hugging Face, każdy plik sprawdzany sumą SHA-256.

Opcja, domyślnie wyłączona

Bielik 11B w polskiej chmurze (CloudFerro Sherlock, PCSS AI HUB) na kluczu użytkownika. Poza liczbami w zgłoszeniu.

Dlaczego małe modele

Dwa małe Bieliki. Każdy do swojej roboty.

Bielik 1.5B v3.0 Instruct

Korekta dyktowania i poprawki transkryptu. Musi zdążyć, zanim puścisz klawisz i sięgniesz po myszkę.

Plik	Q8_0, 1,70 GB
Okno serwera	8 192 tokeny
Pierwszy token	0,07 s (mediana)
Generowanie	ok. 47 tokenów na sekundę

Bielik Minitron 7B v3.0 Instruct

Tryby AI, notatki z godzinnej rozmowy, pytania o spotkania. Potrzebuje dużego okna i lepszego rozumienia.

Plik	Q4_K_M, 4,50 GB
Okno serwera	24 576 tokenów
Pierwszy token	0,41 s (mediana)
Generowanie	ok. 18 tokenów na sekundę, prompt ok. 212

16 GB RAM

Obie role lokalnie. Modele działają po kolei, według zmierzonej pamięci.

24 GB RAM i więcej

Oba modele zostają w pamięci, bez przeładowań.

Poniżej 16 GB

Tryb eksperymentalny: korekta lokalnie, funkcje AI na 1.5B albo w chmurze.

Mierzone na MacBooku Pro M3 Pro, 36 GB RAM, llama.cpp z Metal

Strażnik słów

Mały model poprawia, ale nie zmienia Twoich słów.

Na brudno, z Whispera

~~yyy~~ Jutro o dziesiątej spotkanie z Markiem w sprawie oferty. ~~no~~ Wyślę ją dziś.

Na czysto, przy kursorze

Jutro o dziesiątej spotkanie z Markiem w sprawie oferty. Wyślę ją dziś.

Przepuszcza

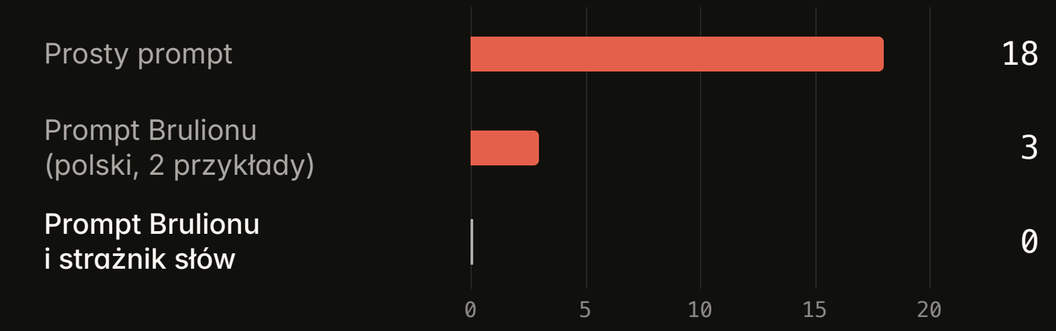
- interpunkcję i wielkie litery
- polskie znaki, drobne literówki
- terminy ze słownika
- usunięte wypełniacze

Cofa do oryginału

- każdą inną zmianę słowa
- streszczenie, odpowiedź na treść
- zmianę osoby lub rodzaju

Odpowiedzi daleko od dyktowania

Bielik 1.5B, 60 prawdziwych dyktowań; streszczenie, odpowiedź na treść albo pętla zamiast korekty



60 z 60

dyktowań z zachowanym sensem. Bez strażnika 1.5B zmieniał sens w 8-15%.

0,82 → 0,89

trafność interpunkcji (F1) wobec chmury, od surowego Whispera do korekty.

Bielik 4.5B po strażniku: WER 0,181 wobec 0,183 dla 1.5B, ale 2,7 raza wolniej. Domyślny jest 1.5B.

docs/benchmark.md

Czas

Korekta w sekundę. Notatki z godziny w kilka minut.

Dyktowania do 60 słów, w sekundach

Brulion.app bez okna, przez prawdziwe trasy, limity i strażnika; rozgrzany serwer



Chmura jest szybsza. Cel z planu, 95% korekt do 3 s, spełniony: 2,49 s.

Tryby AI, Minitron 7B

ok. 10 s

Mediana: e-mail, lista zadań, uporządkuj myśli. Gdy model nie zdąży (3 z 36), wkleja się surowy tekst.

Notatki AI, Minitron 7B

2-3 min

Notatki z 30-44 minut rozmowy, liczone w tle po spotkaniu.

Notatki AI z godziny

ok. 6 min

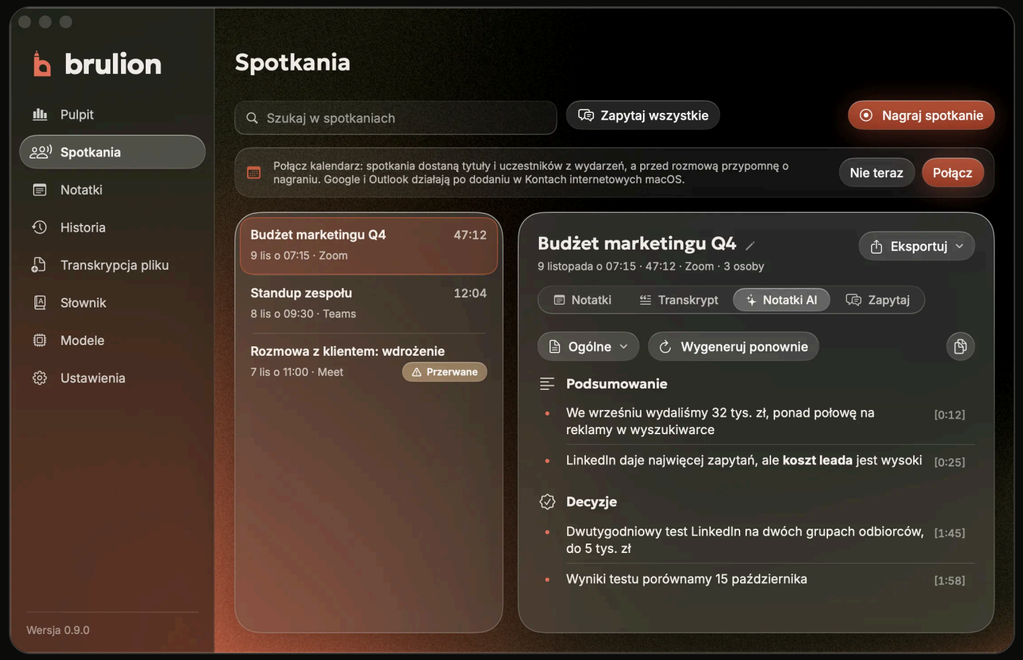
Długi transkrypt dzielony na części i scalany. Test na stenogramie Sejmu z 23 mówcami.

MacBook Pro M3 Pro, 36 GB RAM / 60 dyktowań autora, bez danych klientów

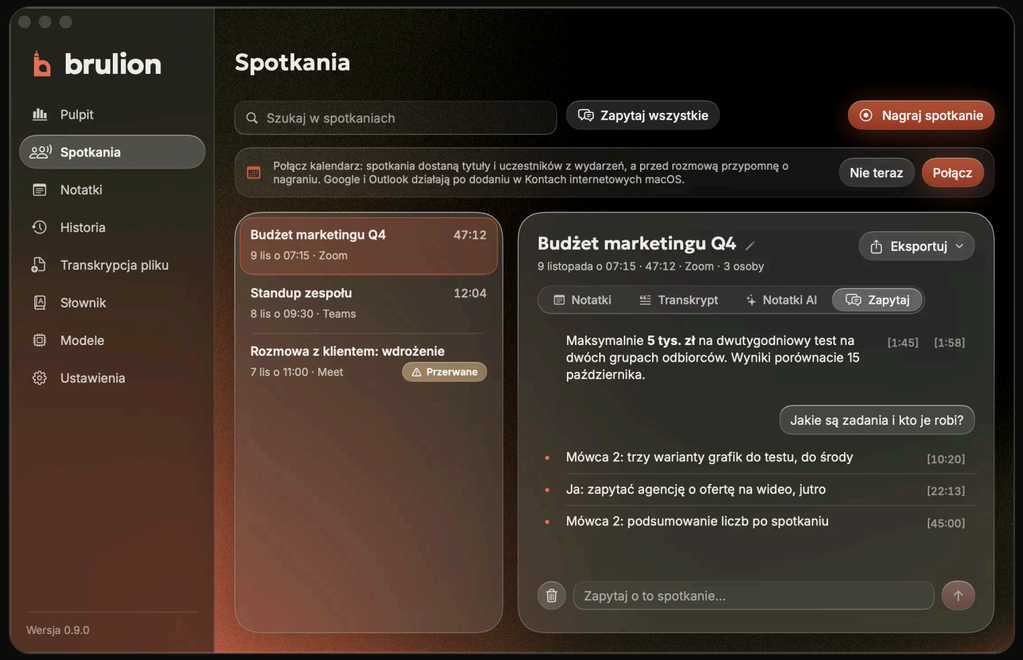
docs/benchmark.md

Spotkania

Spotkania bez bota. Notatki powstają na Macu.



Notatki AI. Podsumowanie, decyzje i zadania, każdy punkt z cytatem [mm:ss]. Poprawki transkryptu pilnuje strażnik linii: bez niego 1.5B psuł 62 z 306 czystych linii.



Zapytaj. O jedno spotkanie albo o wszystkie, odpowiedź ze źródłami. Rozmowa dłuższa niż okno modelu idzie jako notatki i fragmenty pasujące do pytania.

Prywatność, pamięć, koszt

Głos zostaje na Macu. 0 zł za użycie, bez konta.

0

połączeń z internetem w trakcie pracy

- **Gniazda co 0,5 s:** w ok. 150 dyktowaniach i 4 spotkaniach tylko 127.0.0.1.
- **Klatka bez sieci** (sandbox-exec): korekta 6 z 6, e-mail 3 z 3, spotkanie od nagrania do Zapytaj.
- **Bez telemetrii**, automatycznych aktualizacji i naszego serwera. Licznik użycia tylko lokalnie.

Pamięć i dysk, szczyt w pomiarach

Proces	Plik	RAM (RSS)	Pamięć robocza
Serwer z Bielikiem 1.5B okno 8 192	1,70 GB	2,0 GB	0,40-0,42 GB
Serwer z Minitronem 7B okno 24 576	4,50 GB	8,3-8,45 GB	4,0-4,4 GB
Brulion z Whisperem aplikacja 59 MB	1,5 GB	0,1-0,3 GB	-

RSS obejmuje plik modelu zmapowany w pamięci, który macOS zwalnia bez swapu.

Komputer	Pełna lokalna AI	Miejsce
Mac z Apple Silicon, macOS 14.4+	16 GB RAM	ok. 7,2 GB na Bieliki

Sieć tylko przy pobieraniu modeli z Hugging Face i w opcjonalnym trybie chmury

docs/benchmark.md

Dojrzałość i otwarty kod

Wydana aplikacja, nie prototyp.

Z Captylo

Fork wydanego Captylo 1.0.17 (od 09.2026, Developer ID, notaryzacja). Bez konta, płatności i naszej chmury.

GPLv3

Kod, prompty pod Bielika i pomiary są publiczne. Każdy może sprawdzić, co dzieje się z głosem.

Podpisany DMG

Instalator podpisany i poświadczony przez Apple, razem z helperem llama-server.

ok. 1350 testów

Natywny Swift i SwiftUI, ok. 51 tys. linii. Lokalna AI to osobny moduł.

Do powtórzenia

Tryb bez okna przez prawdziwe trasy aplikacji i skrypt pobierający stenogramy Sejmu.

Obok Captylo

Osobne dane i skróty. Przewodnik pobiera Bieliki dobrane do pamięci Maca.

Co dalej

- Tryb lokalny jako opcja w Captylo dla wszystkich użytkowników
- Kolejne wersje Bielika i test na Macu z 8 GB RAM

Strona	kawalec.pl/brulion
Kod	github.com/dawidkawalec/brulion
Autor	Dawid Kawalec, CRAFTWEB Sp. z o.o.

Bielik jest modelem językowym i znakiem Fundacji SpeakLeash. Brulion działa na Bieliku, ale jest niezależnym projektem CRAFTWEB i nie jest produktem SpeakLeash.